

RAG (Retrieval Augmented Generation)

Termine inventato da **Meta nel 2020**.

Accesso dell'LLM a **fonti esterne**: web (caso tipico), db esterni, db vettorizzati.

In ogni punto del flusso prompt → risposta. Ad esempio, da semplice aumento del prompt a modifica interna del modello.

ChatGPT è fornito di una componente di retrieval che cerca informazioni rilevanti su internet e le fornisce al modello perché le usi per rispondere meglio agli utenti. Questo è un esempio tipico di Retrieval Augmented Generation, altri esempi attingono a banche dati specializzate per fornire alla AI generativa informazioni settoriali o relative a una certa azienda o organizzazione.

La RAG fin dall'inizio (l'articolo iniziale) è stata associata alla tecnica dell'**embedding**, capace di proiettare documenti di testo (suddivisi in **chunk**, cioè pezzi) all'interno di uno spazio vettoriale (chiamato appunto embedding) in modo tale da poter facilmente applicare un algoritmo di ricerca di prossimità per trovare documenti che abbiano tra loro un contenuto semanticamente affine.

DB vettorizzato + ricerca semantica per keyword danno i migliori risultati.

Chunking → Storing → Retrieval

